SISTEMA DE ANÁLISIS Y PRONÓSTICO DE RENTAS CEDIDAS

Reporte Técnico de Procesamiento de Datos

Entidad: Municipio de Quibdó

Proyecto de Tesis de Maestría

0. # Proceso de Limpieza y Depuración de Datos

Este documento detalla el procedimiento técnico seguido para la consolidación y limpieza del dataset de Recaudo de Rentas Cedidas utilizado en la tesis.

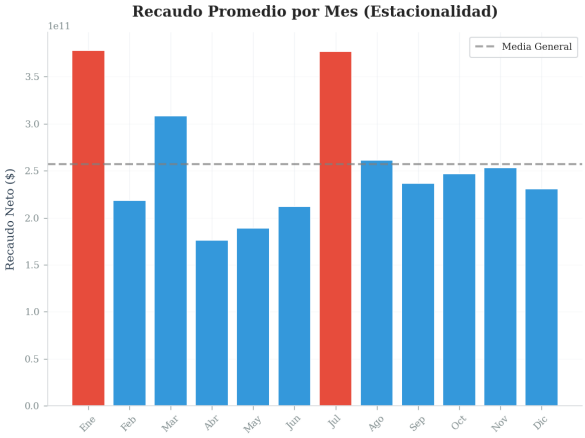

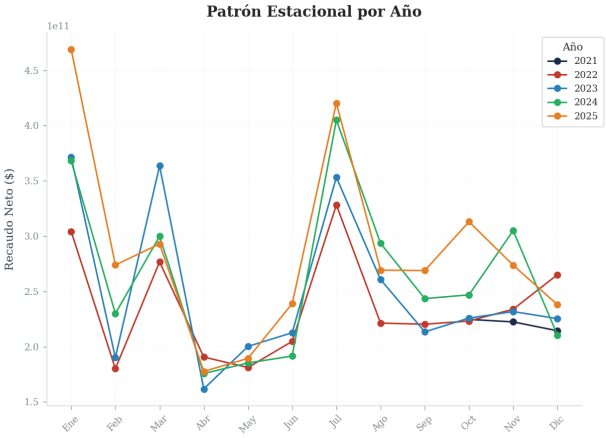

1. 1. Consolidación de la Fuente de Datos

El dataset original se basa en el archivo BaseRentasVF_limpieza21feb_FINAL.xlsx. Este archivo representa la versión final tras integrar múltiples fuentes transaccionales y aplicar filtros de calidad.

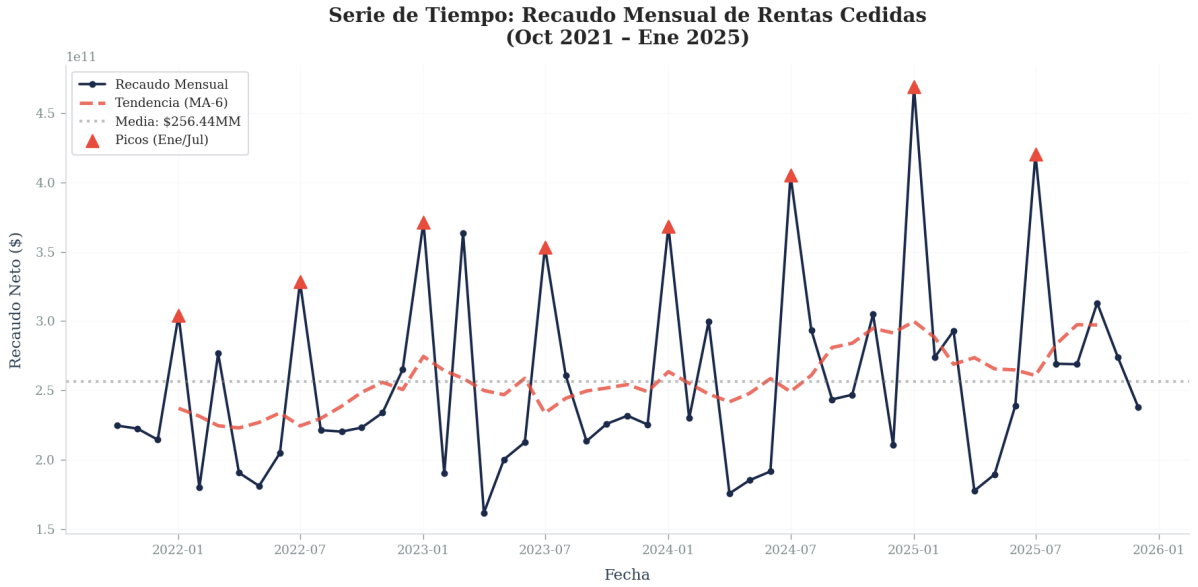

2. 2. Truncamiento Metodológico (Ruptura Estructural COVID-19)

Se aplicó un criterio de exclusión temporal para garantizar la estabilidad de los modelos predictivos:
- Periodo Excluido: Todo el año 2020 y el periodo Enero-Septiembre de 2021.
- Justificación: Los datos de 2020 y principios de 2021 presentan anomalías extremas debido a los cierres económicos de la pandemia, lo que introduciría sesgos artificiales en la varianza y la tendencia.
- Periodo Actual de Estudio: Desde el 1 de octubre de 2021 hasta la fecha actual disponible (Diciembre 2025 en proyecciones/cierres).

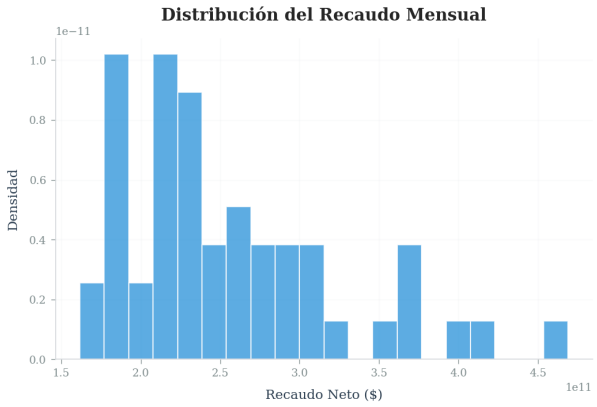

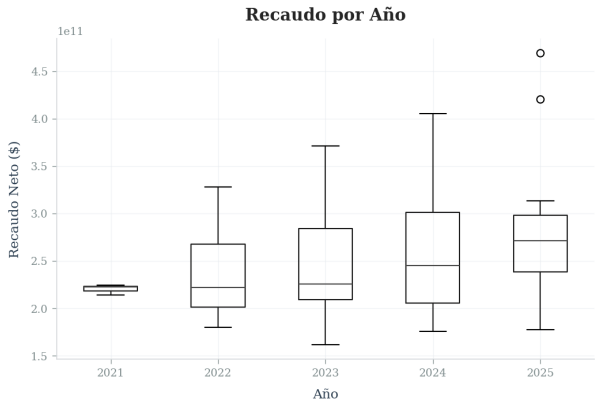

3. 3. Depuración de Registros Atípicos

En el notebook 01_EDA_Completo.ipynb se identificaron y trataron:
- Valores Negativos: Se detectaron 26 registros con valores negativos, correspondientes a ajustes contables o devoluciones. Estos se mantienen para el cálculo del Recaudo Neto, que es la variable objetivo real de sostenibilidad financiera.
- Valores Cero: 3 registros detectados, tratados como ausencia de recaudo efectivo en el rubro específico.
- Nulos: El dataset final tiene 0 valores nulos en la columna crítica ValorRecaudo.

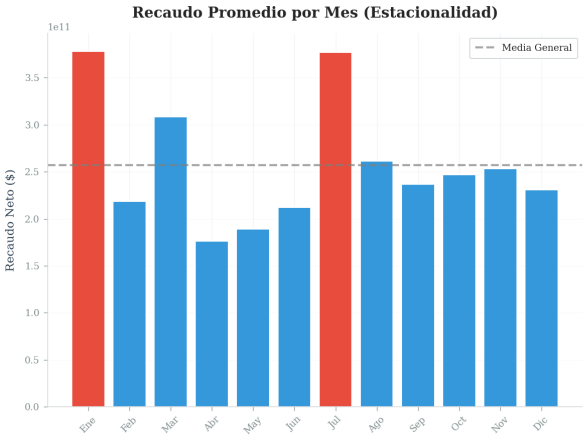

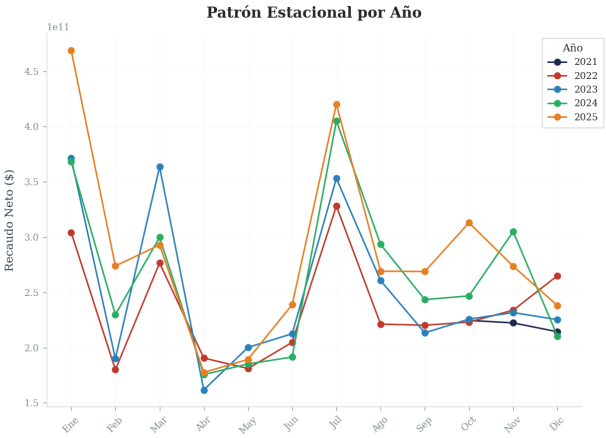

4. 4. Agregación y Regularización Temporal

Dado que el recaudo es transaccional (varios registros por día), se procedió a la regularización:
- Frecuencia: Mensual (*Monthly Start*).
- Variable Objetivo: Recaudo_Neto (Suma de ValorRecaudo por mes).
- Observaciones finales: 51 meses de datos continuos.

5. 5. Validación Estadística

Tras la limpieza, la serie mensual presenta:
- Promedio: ~$256.44MM
- Coeficiente de Variación: 27.0% (Indicador de volatilidad moderada-alta, justificando el uso de modelos complejos como XGBoost y LSTM).
- Estacionariedad: Verificada mediante el test de Dickey-Fuller aumentado (ADF) en el notebook 02_Estacionalidad.ipynb.